Optimisation du code par GCC

Evan VOYLES, Amaury RODRIGUEZ, Stefan GAŁKIEWICZ

20 janvier 2022

Notions de compilation

Il y a une particuliere puissance caché derrière les trois lettres gcc - signifiant à la fois la 'Gnu Compiler Collection' et la commande à lancer dans le terminal pour compiler un program C. Enfin pas que. Quand on appelle une commande de la forme

```
gcc -o hello hello_world.c
```

on lance effectivement une multitude de processus qui travaillent scrupuleusement en silence. Il s'agit de :

1. Préprocesser le fichier .c
2. Compiler les fichiers processés pour créer des fichier d'objet (.o)
3. Relier des fichiers d'objet dans une éxécutable

Ca veut dire quoi, préprocesser un fichier .c? En effet, à chaque fois qu'on écrit `#include <stdio.h>` pour inclure un fichier d'entête, avant la compilation un outil dit le préprocesser va remplacer une ligne d'include avec tout le contenu du fichier d'entête. Alors la directive préprocesseur `#include` consiste en une opération de copier et coller. Il y a plusieurs d'autres directives qui sont processées avant de compiler, par exemple le lecteur reconnaitra peut-etre les directives

```
#if, #ifdef, #ifndef, #else, #elif
```

qui sont employées pour la compilation conditionnel (par exemple, inclure un fichier spécifique pour Windows si le système est Windows) où bien pour éviter d'inclure le même fichier plusiers fois :

```
#ifndef MONFICHIER_H
#define MONFICHIER_H

/ Contenu du fichier monfichier.h /

...

#endif
```

Après que nos fichiers sont préprocessés, ils sont prêts pour être compilés. La compilation traduit des fichiers en C à des instructions de machine en binaire, dit des fichiers d'objet qui portent l'extension .o. Pour experimenter chez vous, on peut donner l'option `-c` à gcc pour arrêter après le compilation et créer des fichiers d'objet. Le dernier étape s'agit de regrouper tout les fichiers d'objet pertinents et de les emballer dans une seule exécutable. C'est quoi la différence concrète entre un 'program' C et une 'bibliothèque'? Une bibliothèque c'est une collection des fonctions et leur définitions tandis ce que un program contient la fonction spécial `main`, qui sert comme une porte d'entrée de l'exécution d'un program.

Alors finalement l'outil `ld`, dit le 'linker' en anglais, relie tous les fichiers .o dans un executable. Son travail est compliqué mais fondamentale. Grosso modo, `ld` trouve exactement où elle sont définies les fonctions extérieures qu'on appelle dans un program. Par exemple, pour un program simple HelloWorld on va utiliser la fonction `printf` qui est défini d'ailleurs. Au moment de créer l'exécutable, `ld` va chercher la définition de `printf` dans la bibliothèque standarde et mettre les instructions binaires dans l'exécutable. La magie de gcc c'est qu'il a fait tout cela pour vous en coulisse - un vrai emploi ingrat.

L'Optimisation

Pendant l'étape de compilation, le compileur peut analyser votre code et effectuer des optimisations, si vous le souhaitez. Il y a une centaine des options pour le compileur dont au moins cinquante pour l'optimisation. Les options pour changer le comportement d'optimisation commence par un -f, suivi par le nom de l'option. Comme il y des nombreuses optimisations spéficiques, gcc a regroupé les stratégies d'optimisation qui ont le même objective de compilation. C'est-à-dire que certaines optimisations pourraient rendre le code plus vite mais également augmenter la taille de l'exécutable. Alors les classes se divisent en différents niveaux de -O.

-O0

Désactiver la plupart des optimisations.

-O1

Le principe c'est de réduire le temps d'exécution aussi la taille du binarie. Au niveau -O1 la compilation est un peu plus longue mais pas beaucoup comme a ce niveau les optimisations restent quand même sipmles.

Le premier niveau d'optimisation actives les options suivantes

```
-fauto-inc-dec
-fbranch-count-reg
-fcombine-stack-adjustments
-fcompare-elim
-fcprop-registers
-fdce
-fdefer-pop
-fdelayed-branch
-fdse
-fforward-propagate
-fguess-branch-probability
-fif-conversion
-fif-conversion2
-finline-functions-called-once
-fipa-modref
-fipa-profile
-fipa-pure-const
-fipa-reference
-fipa-reference-addressable
-fmerge-constants
-fmove-loop-invariants
-fmove-loop-stores
```

```
-fomit-frame-pointer
-freorder-blocks
-fshrink-wrap
-fshrink-wrap-separate
-fsplit-wide-types
-fssa-backprop
-fssa-phiopt
-ftree-bit-ccp
-ftree-ccp
-ftree-ch
-ftree-coalesce-vars
-ftree-copy-prop
-ftree-dce
-ftree-dominator-opts
-ftree-dse
-ftree-forwprop
-ftree-fre
-ftree-phiprop
-ftree-pta
-ftree-scev-cprop
-ftree-sink
-ftree-slsr
-ftree-sra
-ftree-ter
-funit-at-a-time
```

-O2

Le deuxième niveau active plus des optimisations. Sans échanger la taille de l'exécutable pour la vitesse du programme, ce niveau ralentit le temps de compilation mais augmente la performance des instructions genérées. Les options activées à ce niveau-là ce sont toutes les options de -O2 plus :

```
-falign-functions  -falign-jumps
-falign-labels  -falign-loops
-fcaller-saves
-fcode-hoisting
-fcrossjumping
-fcse-follow-jumps  -fcse-skip-blocks
-fdelete-null-pointer-checks
-fdevirtualize  -fdevirtualize-speculatively
-fexpensive-optimizations
-ffinite-loops
-fgcse  -fgcse-lm
-fhoist-adjacent-loads
-finline-functions
-finline-small-functions
-findirect-inlining
-fipa-bit-cp  -fipa-cp  -fipa-icf
-fipa-ra  -fipa-sra  -fipa-vrp
-fisolate-erroneous-paths-dereference
-flra-remat
```

```
-foptimize-sibling-calls
-foptimize-strlen
-fpartial-inlining
-fpeephole2
-freorder-blocks-algorithm=stc
-freorder-blocks-and-partition  -freorder-functions
-frerun-cse-after-loop
-fschedule-insns  -fschedule-insns2
-fsched-interblock  -fsched-spec
-fstore-merging
-fstrict-aliasing
-fthread-jumps
-ftree-builtin-call-dce
-ftree-loop-vectorize
-ftree-pre
-ftree-slp-vectorize
-ftree-switch-conversion  -ftree-tail-merge
-ftree-vrp
-fvect-cost-model=very-cheap
```

-O3

Un troisième niveau active les optimisations les plus violentes et n'hésitantes pas à créer une exécutable plus grandes au nom de la vitesse. Les options activé dans ce niveau sont :

```
-falign-functions  -falign-jumps
-falign-labels  -falign-loops
-fcaller-saves
-fcode-hoisting
-fcrossjumping
-fcse-follow-jumps  -fcse-skip-blocks
-fdelete-null-pointer-checks
-fdevirtualize  -fdevirtualize-speculatively
-fexpensive-optimizations
-fgcse  -fgcse-lm
-fhoist-adjacent-loads
-finline-functions
-finline-small-functions
-findirect-inlining
-fipa-bit-cp  -fipa-cp  -fipa-icf
-fipa-ra  -fipa-sra  -fipa-vrp
-fisolate-erroneous-paths-dereference
-flra-remat
-foptimize-sibling-calls
-foptimize-strlen
-fpartial-inlining
-fpeephole2
-freorder-blocks-algorithm=stc
-freorder-blocks-and-partition  -freorder-functions
-frerun-cse-after-loop
-fschedule-insns  -fschedule-insns2
-fsched-interblock  -fsched-spec
-fstore-merging
-fstrict-aliasing
-fthread-jumps
-ftree-builtin-call-dce
-ftree-loop-vectorize
-ftree-pre
-ftree-slp-vectorize
-ftree-switch-conversion  -ftree-tail-merge
-ftree-vrp
-fvect-cost-model=very-cheap
```

Options Spécifiques

Comme on a vu dans le dernier section, il y a de nombreuses options activé avec chaque niveau optimisation et il ne serait pas intéressant de vous dénombrer que fait chacun. Donc, on va choisir juste quelques unes à étudier qui sont utilisé souvent.

Enlever le code superflu

Pour optimiser le code le compilateur peut enlever du code redondant, en effet le but de l'optimisation du code est de réduire la taille et augmenter la vitesse d'exécution du code. Une des premières optimisations qui paraît évident est d'enlever le code qui ne sert pas. Il s'agit principalement de deux types du code redondant - dead code (DC, code mort) et dead storage (DS, stockage mort). Tout segment du code qui ne s'execute pas est dit mort.

-fdce, -ftree-dce

Étudions le segment du code suivant :

```
if (1 < 2) {
    printf("1 est plus petit que 2");
} else {
    printf("Ca marche plus les maths");
}
```

Ici le compilateur va remarquer qu'il y a un segment de code mort et en déduire que l'on peut optimiser. Comme nous le voyons dans le code ci-dessus, la condition `1 < 2` est toujours vérifié donc la condition du `if` n'a pas besoin d'être testé et le `else` ne sera jamais exécuté. Vu que la ramification dun programme peut notoirement effectuer des ralentissements d'éxecution, `gcc` peut enlever la branche `if` et effacer le code mort, sous condition que les options `-fdce` et `-ftree-dce` soient activées.

En fait, l'optimisation du code mort est si important que ca que gcc enlève automatiquement dans certains cas :

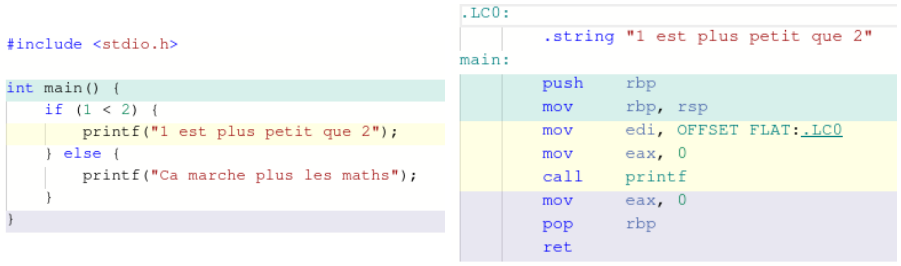

Figure 4 – Instructions en assemblée genérées pour x86-64 par gcc pour un program simple. Le code mort après else ne se traduit même pas.

N'ayez pas peur de l'assemblée ! Comme nous le pouvons constater, les instructions pour la deuxième branche de l'expression `if` ne sont même pas genérées (indiqué par le manque de couleur surlignante la deuxième `printf`) !

On peut comparer cet exemple avec un program simple similaire, mais qui diffère cette fois-ci parce que le compileur ne peut pas déterminer si la condition est toujours vérifié. Étudions le program suivant.

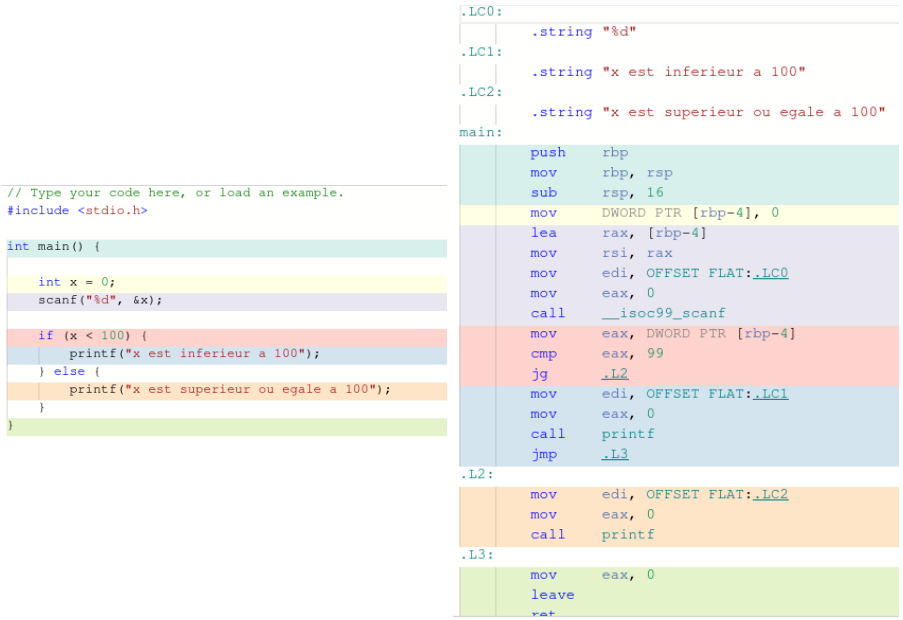

Figure 5 – Exemple où des instructions sont genérées pour les deux branches du if

Vu que la condition dans le `if` est dependant sur une donnée d'entrée qui se processe a l'exécution, il est impossible de déterminer au moment de compilation si le code est mort. Du coup, il n'y a aucun optimisation dans cet example.

-fdse, -ftree-dse

Ces options traiten le cas où il y a des variables mortes - c'est-à-dire des variables qui ne sont jamais accedées. Par exemple dans le code qui suit, la variable y n'est pas utilisée. Pour optimiser le code il suffit juste de retirer la ligne et ainsi réduire la taille et augmenter la vitesse d'exécution du code. Cela marche aussi avec des fonctions qui ne font rien ou ne sont pas utilisés.

```
int my_func() {
    int x = 5;
    int y = 5;
    return x;
}
```

On peut étudier l'assemblé pour visualiser les optimisation fait par gcc.

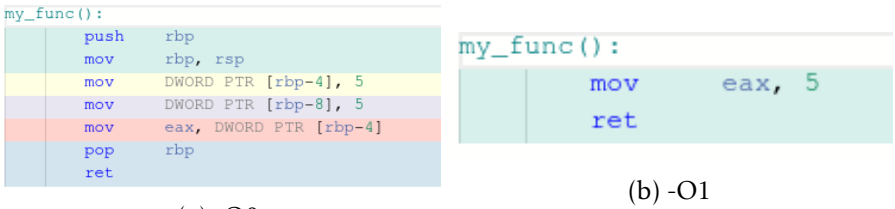

(a) -O0

(b) -O1

FIGURE 6 – Exemple où le DSE est enlèvé

La fonction entière est remplacée par une instruction de charger la valeur 5 dans un registre du CPU.

Optimisation des boucles

Nous allons etudier ici quelques options qui permettent d'optimiser la compilation des boucles.

-fpeel-loops

Le peeling de boucle est un cas particulier du découpage de boucle. Le découpage de boucle est une méthode d'optimisation du compilateur. Celui-ci elimine les dépendances. Il simplifie la boucle en plusieurs boucles afin d'éliminer des dépendances. Ainsi ces boucles auront le meme corps mais vont itérer différentes parties de la boucle. La particularité du peeling de boucle va être que si le compilateur détecte une ou quelques itérations problématiques il va la sortir de la boucle et l'exécuter en dehors de la boucle (c'est pour cela que ca s'appelle l'épluchage). Ainsi si l'on a par exemple

```
int p = 10;
for (int i=0; i<10; ++i) {
```

```
    y[i] = x[i] + x[p];
    p = i;
}
```

le compilateur avec fpeel-loops va remarquer que p=10 seulement a la première itération et donc il va compiler comme si le code était écris

```
y[0] = x[0] + x[10];
for (int i=1; i<10; ++i) {
   y[i] = x[i] + x[i-1];
}
```

et donc on peut remarquer que le p ici n'est plus utilisé et est remplacé par directement 10 et la première itération est sorti du corps de la boucle et est remplacé par y[0] = x[0] + x[10];

-fmove-loop-invariants

Le loop invariant loop est une optimisation du compilateur qui permet de sortir un invariant d'une boucle sans changer sa semantique. Par exemple :

```
int i = 0;
while (i < n) {
    x = y + z;
    a[i] = 6 * i + x * x;
    ++i;
}
```

On peut voir que x=y+z est un invariant dans la boucle et donc le fmove-loop-invariants va le sortir de la boucle sans en changer le sens.

-funswitch-loops

le funswitch-loops est une methode d'optimisation du compilateur qui va permettre de sortir une condition situe a linterieur d'une boucle a l'exterieur de celle-ci. Pour ceux elle va dupliquer le corps de la boucle en en placant a l'interieur de conditions qui etaient de base a l'interieur. Cela permet d'avoir une meilleure parrallelisation de la boucle (c'est une technique d'optimisation de boucle) et donc ameliore la vitesse du programme. Montrons un exemple de funswitch-loops

```
int i, w, x[1000], y[1000];
  for (i = 0; i < 1000; i++) {
    x[i] += y[i];
    if (w)
      y[i] = 0;
  }
```

ici on peut sortir le ‘`if (w)`’ et dupliquer les boucles for. Ainsi le compilateur pourra transformer cela en

```
int i, w, x[1000], y[1000];
  if (w) {
    for (i = 0; i < 1000; i++) {
      x[i] += y[i];
      y[i] = 0;
    }
  } else {
    for (i = 0; i < 1000; i++) {
      x[i] += y[i];
    }
  }
```

Dernières Remarques

Comme il y a un vaste nombre des options d’optimisations, on aurait aimé de vous en parler de plus ! Malheuresement on aura plus de l’espace. Ce qu’il faudrait retenir du coup pour la suite c’est qu’il y des niveaux d’optimisations constructifs qui permet au programmeur de choisir si l’on veut réduire la taille du binaire ou le temps d’exécution. On peut activer une groupe des options à la fois avec les options -O1, -O2, ou -O3. Il y a aussi des autres groupes de O telles que -Og, -Oz, -Os, -Ofast que je vous encourage de vous en renseigner. On peut activer des optimisations spécifiques avec une option commenceant par -f, -fno sinon pour le désactiver. Par exemple, l’on a -ffast-math pour activer ou bien -fnofast-math pour le désactiver. En conclusion, on espère que ce rapport vous a appris quelque chose du processus de compilation et qu’on vous a allumé une appréciation pour la magique qui est gcc.